

Highlights*

1. Include 3 to 5 bullet points that convey the main findings of the work.
2. Methods and results are not “findings,” so they should not appear as highlights.
3. Bullets are limited to a maximum of 85 characters, including spaces.
4. Bullets should be complete sentences, not sentence fragments.
5. Highlights should be able to stand alone, so avoid acronyms or specialized terms.

* Please note: Highlights are not part of the manuscript document but should be submitted in a separate editable file in the online submission system. Please use “Highlights” in the file name.

Also, in the submission’s cover letter, authors should clearly state what are the key contributions of their work and why their contributions are novel and worthy of journal consideration.

A Knowledge Graph-Enhanced Large Language Model Framework for Goat Disease Question Answering System

⁵ ^a Please clearly indicate the given name(s) and family name(s) of each author and check that all names are
⁶ accurately spelled. Most COMPAG papers have three to six authors (please refer to the Author Statement
⁷ guidance on the last page of this document).

^b Present the authors' affiliation addresses (where the actual work was done) below the names. Indicate all affiliations with a lower-case superscript letter immediately after the author's name and in front of the appropriate address. Provide the full postal address of each affiliation, including the country name and, if available, the e-mail address of each author.

12 ^c Authors are expected to carefully consider the list and order of authors **before** submitting their manuscript
13 and provide the definitive list of authors at the time of the original submission. Any addition, deletion, or
14 rearrangement of author names in the authorship list should be made only **before** the manuscript has been
15 accepted and only if approved by the journal Editor.

16 * Clearly indicate who will handle correspondence at all stages of refereeing and publication, also post-
17 publication. This responsibility includes answering any future queries about Methodology and
18 Materials. **Ensure that the e-mail address is given and that contact details are kept up to date by the**
19 **corresponding author.**

21 Abstract

隨著精準畜牧（Precision Livestock Farming, PLF）的發展，畜牧產業對即時、正確且具一致性的專業知識需求日益提升。然而，在台灣山羊產業等資料相對稀缺的畜牧場域中，疾病防治與飼養管理知識多以非結構化文本形式分散於官方技術手冊與專家文件中，難以直接整合至智慧化決策支援系統，亦限制現有問答系統於實務應用中的效能與可靠性。

26 為回應上述挑戰，本研究提出一套結合知識圖譜（Knowledge Graph, KG）與圖譜式檢索
27 增強生成（Graph-based Retrieval-Augmented Generation, GraphRAG）的台灣山羊疾病問答
28 系統分析架構。本研究以農業部畜產試驗所之權威技術文件為知識來源，建構台灣本土山
29 羊疾病知識圖譜（Goat-KG），將分散的非結構化文本轉換為具語意關聯性與可推理性的
30 結構化知識表示。不同於既有研究多聚焦於模型或單一系統配置之效能比較，本研究從系
31 統工程角度出發，系統性探討知識建構參數（如文本切分大小與重疊率）、圖譜拓樸結構
32 品質，以及檢索配置對問答效能之影響。

33 實驗設計包含參數掃描（Parameter Sweep）與消融實驗（Ablation Study），用以量化圖譜
34 結構指標（如關係密度、節點連通性與弱連結比例）與問答表現之關聯性，並分析在不同
35 圖譜結構品質條件下，Graph-based RAG 系統於多跳推理任務中的行為特性與效能變化。
36 實驗結果顯示，相較於未使用外部知識之大型語言模型（LLM-only）與傳統向量式 RAG
37 方法，本研究所提出之 Graph-based RAG 架構在山羊疾病問答任務中展現較高的回答準確
38 性與語意一致性，尤以涉及多實體關聯與跨概念推理之問題情境中最為顯著。

39 綜合而言，本研究不僅驗證結構化知識圖譜於畜牧問答系統中的實務價值，亦提出一套具
40 可重現性的知識圖譜建構、結構診斷與 Graph-based RAG 問答整合流程，為智慧畜牧與農
41 業知識工程應用提供具體且可操作之系統設計參考。

42 **Keywords.** Agricultural knowledge graph; Graph-based retrieval-augmented generation; Multi-
43 hop question answering; Knowledge graph topology; Structural graph optimization; Precision
44 livestock farming

45 **1. Introduction**

46 隨著智慧農業（Smart Agriculture）與精準畜牧（Precision Livestock Farming, PLF）的快速

47 發展，資訊科技逐漸被導入傳統畜牧生產流程，以提升飼養管理效率、疾病防治能力與整
48 體決策品質。在畜牧生產情境中，尤其是以中小規模經營為主的產業型態，疾病診斷、用
49 藥選擇與日常飼養管理高度仰賴即時且正確的專業知識。然而，相關知識多來自分散且表
50 述方式不一致的資料來源，使得其在實務應用上難以被系統化整合與有效利用。

51 在台灣山羊產業中，此一問題尤為顯著。與山羊疾病、防治與健康管理相關的專業知識，
52 主要散佈於官方技術手冊、研究報告與專家審定文件中。這些資料雖具有高度權威性，卻
53 多以非結構化文本形式存在，缺乏明確的語意關聯與可推理結構，導致基層飼養者在實務
54 操作中，往往仍需依賴個人經驗或零散資訊進行判斷。此種知識取得與應用方式，不僅影
55 響資訊一致性，也限制了智慧化決策支援系統在畜牧場域中的實際落地。

56 近年來，大型語言模型（Large Language Models, LLMs）於自然語言理解與生成任務中展
57 現良好表現，逐漸被應用於農業諮詢與問答系統中。然而，若缺乏明確的領域知識約束，
58 模型所產生的回應仍可能與實際專業建議存在落差，特別是在需要精確對應疾病、症狀與
59 處置流程的畜牧應用情境下。因此，如何確保模型回應具備可追溯的知識依據與一致性，
60 成為農業問答系統設計中的重要課題。

61 為提升問答系統之可靠性，檢索增強生成（Retrieval-Augmented Generation, RAG）架構被
62 提出，透過在回應生成過程中結合外部知識來源，使模型能基於實際資料進行回應。現有
63 農業相關 RAG 研究多採用向量式文本檢索，以語意相似度為基礎擷取相關文本片段作為
64 上下文。然而，在涉及多個概念關聯與跨段落資訊整合的畜牧問題中，此類方法往往難以
65 有效支援多步推理與結構化知識關聯，限制了系統在複雜問答情境中的表現。

66 相較之下，知識圖譜（Knowledge Graph, KG）能以結構化方式表達實體與關係，具備支
67 援關聯推理與跨概念查詢的潛力。雖然近年已有研究開始探索結合知識圖譜與問答系統的

68 應用，但在農業領域中，多數文獻仍著重於系統展示或單一配置下的效能評估，較少從系
69 統層級分析知識建構參數、圖譜結構品質與問答效能之間的關聯性。
70 基於上述研究背景，本研究以台灣本土山羊產業為實證場域，提出一套結合知識圖譜與圖
71 譜式檢索增強生成（Graph-based RAG）的農業問答系統分析架構。不同於僅關注模型最
72 終輸出的既有研究，本研究從系統工程角度出發，系統性探討知識建構參數、圖譜拓樸結
73 構與檢索配置如何共同影響問答效能，並進一步提出一套具可重現性的知識工程實務流程，
74 作為智慧畜牧應用之參考。

75 **2. Related work**

76 **2.1 Agricultural Knowledge Graphs and Ontology Engineering**

77 近年來，農業與畜牧領域逐漸引入知識圖譜與本體論工程，以系統化方式整合分散於文本、
78 資料庫與專家經驗中的異質知識。相關研究指出，透過明確定義農業生產流程、作物或疾
79 痘相關概念及其關係，可有效提升農業資訊系統在語意一致性與推理能力上的表現[1]。
80 在此脈絡下，本體導向的農業知識圖譜被視為支撐智慧農業決策與問答應用的重要基礎設
81 施[1]。隨著大型語言模型的發展，近期研究亦開始探討結合 LLM 與知識圖譜，以強化知
82 識建構與維護流程的可行性與彈性[2]。

83 在農業知識圖譜建構過程中，從非結構化文本中自動抽取實體與關係被視為關鍵步驟之一。
84 既有研究提出多種基於注意力機制的實體—關係聯合抽取方法，以降低人工標註成本並提
85 升抽取準確度[3]。進一步地，語意與語法資訊的整合被證實能改善農業專業文本中關係
86 識別的穩定性，特別是在疾病防治等高專業語境下具有實用價值[4]。此外，針對農業語
87 言特性所設計的領域語言模型，亦被廣泛應用於命名實體識別與下游知識建構任務中，以
88 補足通用語言模型在農業語彙理解上的不足[5]。

89 除了文本導向的方法外，部分研究亦著重於多來源或多模態資料的整合，以建構更完整的
90 農業知識圖譜。例如，結合專家知識、感測資料與歷史紀錄的疾病知識圖譜，已被應用於
91 作物病害管理情境中，展現其在知識覆蓋與關係建模上的潛力[6]。同時，多模態農業知
92 識圖譜的研究亦顯示，整合影像與文本資訊有助於擴展知識表示能力，惟其建構流程仍相
93 對複雜且成本較高[7]。綜合而言，現有農業知識圖譜與本體工程方法雖已建立重要基礎，
94 但在自動化程度、結構完整性及跨情境泛化能力方面，仍存在進一步深化與系統性分析的
95 空間[8]。

96 **2.2 LLMs and RAG Systems in Smart Agriculture**

97 在大型語言模型（Large Language Models, LLMs）普及之前，人工智慧技術已被廣泛應用
98 於智慧農業與畜牧管理情境中，用以支援生產監測、健康評估與決策輔助等任務。相關綜
99 述研究指出，機器學習與資料分析方法在動物行為辨識、疾病預測及農場管理方面已展現
100 一定成效，顯示農業領域對智慧化決策系統具有長期且穩定的需求[9]。然而，這類系統
101 多屬於任務導向設計，缺乏以自然語言進行整合式知識互動的能力，使其在複雜決策場景
102 中的彈性與可擴展性仍受到限制[9]。

103 隨著 LLM 在自然語言理解與生成能力上的突破，研究者開始嘗試將其導入智慧農業問答
104 與決策支援系統中，以提升人機互動的便利性與知識存取效率。然而，既有研究亦指出，
105 LLM 在專業與低資源領域中容易產生不具事實依據的回應，即所謂的幻覺（hallucination）
106 問題，進而影響系統輸出的可靠性[10]。在農業與畜牧等高度專業且決策風險較高的應用
107 情境中，這類問題尤為關鍵，顯示單純依賴語言模型內部知識進行推論仍存在明顯限制
108 [10]。

109 為降低幻覺風險並提升回答的知識一致性，Retrieval-Augmented Generation(RAG)架構被

110 提出作為結合語言模型與外部知識的重要解法。RAG 透過在生成過程中引入檢索機制，
111 使模型能即時存取與問題相關的文件或知識內容，已被證實在多種知識密集型任務中能有
112 效提升生成品質[11]。後續研究進一步系統化整理 RAG 的設計架構與實作方式，指出透過
113 檢索結果輔助生成，可在一定程度上緩解語言模型因知識不足而產生的錯誤回應[12]。
114 在智慧農業應用中，部分研究開始探討將領域知識明確導入 LLM，以提升其在專業場域
115 中的推理能力。例如，知識導向的農業語言模型透過整合外部知識規則或資料來源，使模
116 型在回應農業相關問題時能更貼近實際專業知識[13]。進一步地，結合知識圖譜與 LLM
117 的研究亦逐漸受到關注，相關實例顯示，透過知識圖譜提供疾病、症狀與處置之間的結構
118 化關係，有助於提升農業疾病診斷問答在一致性與準確性上的表現[14]。
119 儘管上述方法已驗證 LLM 結合外部知識在智慧農業中的應用潛力，既有 RAG 系統多以向
120 量式檢索為核心設計，對知識結構與推理路徑的明確建模仍相對有限[12]。在需要整合多
121 項農業知識進行複雜推理的情境下，此類方法仍可能面臨推理深度與可解釋性不足的問題
122 [15]。因此，如何進一步引入結構化知識表示與檢索策略，以支援更具邏輯性與多步推理
123 能力的智慧農業問答系統，仍有必要進一步探討[15]。

124 **2.3 Graph-based Retrieval and Multi-hop Reasoning**

125 多跳問答（multi-hop question answering）旨在整合多個相互關聯的知識片段，以完成具備
126 邏輯一致性的推理過程，其關鍵挑戰在於如何維持跨步驟推理所需的結構連貫性。既有研
127 究指出，僅依賴文字語意相似度進行檢索，往往無法明確保留知識之間的關係結構，進而
128 限制多步推理的完整性與可靠性[16]。相較之下，圖結構能透過節點與關係明確表示知識
129 間的連結，被視為支撐多跳推理與複雜問答的重要表示形式[16]。在此基礎上，研究者開
130 始嘗試結合大型語言模型與知識圖譜，以提升問答系統在推理過程中的表現。相關工作顯

131 示，透過在圖結構上引導語言模型進行推理，可使生成結果更貼近具有追溯性的推理路徑，
132 並改善回答的可解釋性[17]。後續研究進一步強化語言模型對圖結構的感知能力，使其能
133 在多跳推理任務中更有效地利用節點與關係資訊，從而提升整體問答效能[18]。然而，這
134 類方法多聚焦於推理階段，通常隱含假設知識圖譜本身具備良好的結構品質與完整連通性
135 [18]。

136 隨著檢索增強生成（Retrieval-Augmented Generation, RAG）架構的發展，研究焦點逐漸從
137 「如何在圖上推理」轉向「如何利用圖結構進行檢索」。Graph-based Retrieval 的代表性工
138 作提出，透過圖結構進行社群或子圖層級的檢索，可同時取得多個相互關聯的知識節點，
139 從而維持多跳推理所需的證據鏈[19]。後續研究進一步系統化 GraphRAG 的設計架構，顯
140 示將圖結構納入檢索流程，有助於降低傳統向量式檢索所造成的局部搜尋問題，並提升複
141 雜查詢的整體檢索品質[20]。然而，當知識圖譜係由非結構化文本自動建構時，其結構往
142 往呈現高度破碎或不均的特性，進而影響 Graph-based Retrieval 的實際效能。相關研究指
143 出，碎片化的知識圖譜容易導致檢索過程偏向局部節點，進而使多跳推理路徑中斷或退化
144 [21]。為因應此問題，已有工作嘗試透過重新組織與重構知識圖譜，以緩解結構破碎對檢
145 索與推理行為所造成的不利影響[21]。除了依賴語言模型引導圖走訪(Graph Traversal)外，
146 近期研究亦重新關注由圖結構本身驅動的檢索與推理策略。部分研究提出利用傳統圖演算
147 法，如 spreading activation) 在知識圖譜上進行關聯擴散，使系統能在不高度依賴語言模
148 型決策的情況下，支援多跳文件檢索與知識探索[23]。此類方法顯示，檢索與推理品質在
149 很大程度上取決於圖譜的連通性與結構分布，而非僅由語言模型的生成能力所主導[23]。
150 綜合而言，現有 Graph-based Retrieval 與多跳推理研究已證實圖結構在維持推理連貫性與
151 支援複雜問答上的關鍵角色。然而，多數研究仍假設知識圖譜具備良好結構品質，較少從

152 應用場域角度系統性分析圖譜拓樸特性對檢索與推理效能的影響。在智慧農業等決策導向
153 情境中，如何進一步結合結構品質分析與檢索策略設計，以提升知識驅動問答系統的穩定
154 性與可靠性，仍有必要深入探討[24]。

155 **2.4 Graph Topology Analysis and Structural Optimization**

156 知識圖譜的結構品質被普遍認為是影響下游推理與補全任務效能的重要因素。既有研究指
157 出，不同的圖嵌入與連結預測方法在效能表現上，往往高度依賴圖譜本身的結構特性，例
158 如節點分布與關係密度等[25]。因此，圖譜拓樸不僅作為模型學習的輸入條件，更在很大
159 程度上限制了知識補全與推理能力的上限[25]。隨著圖譜應用逐漸擴展至醫療與生物資訊
160 等高複雜度領域，研究者開始系統性分析圖譜拓樸特性對模型效能的影響。相關研究顯示，
161 節點度數分布不均、連通性不足或過度集中於少數樞紐節點的結構，皆可能導致圖譜補全
162 模型效能顯著下降[26]。此類分析凸顯，若忽略圖譜結構本身的品質問題，即使採用先進
163 模型架構，仍難以在實務情境中穩定發揮效能[26]。

164 近年來，資料中心化（data-centric）的圖學習觀點逐漸受到重視，相關綜述指出，相較於
165 單純追求模型複雜度，改善圖資料品質與結構特性往往能帶來更具體且穩定的效能提升
166 [27]。在此脈絡下，圖譜的結構診斷與優化被視為提升圖學習與推理任務效能的關鍵前處
167 理步驟，而非僅作為模型訓練後的補救措施[27]。

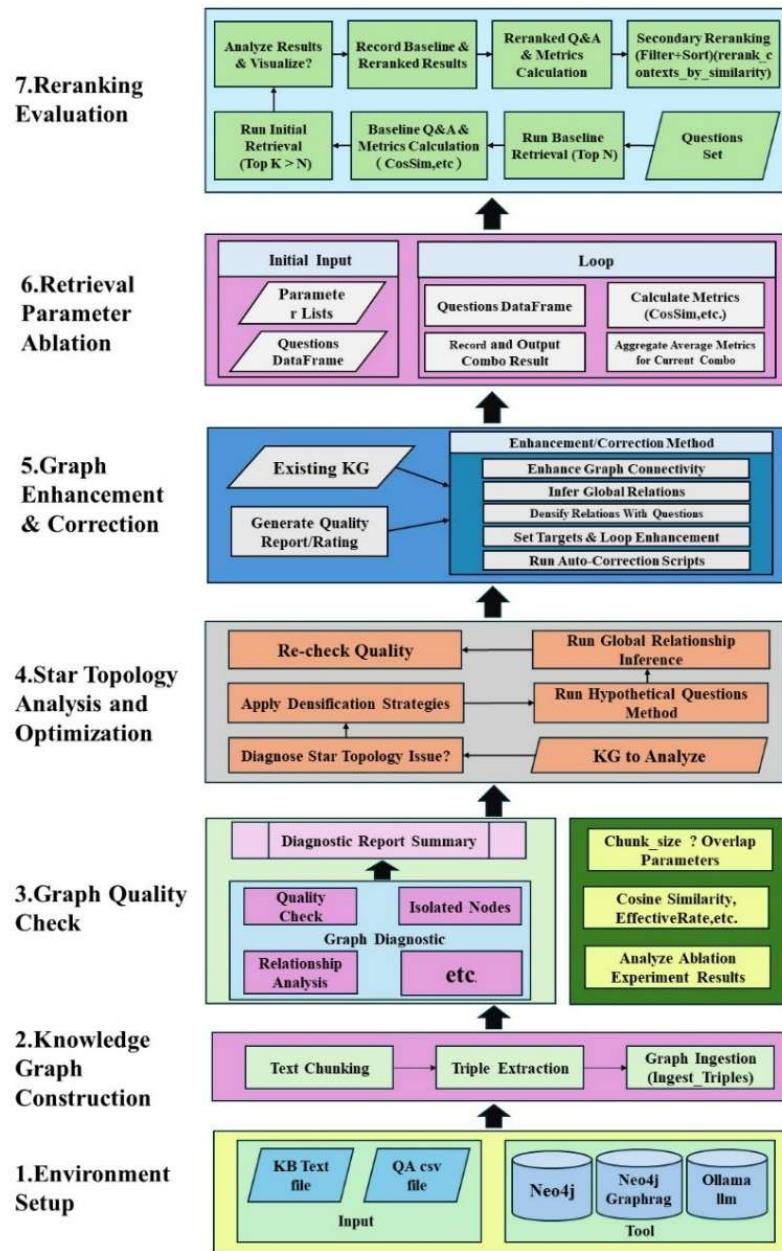
168 在檢索增強生成（RAG）系統中，文本切分策略亦被證實會間接影響所建構圖譜的結構
169 品質。相關研究指出，不同的 chunking granularity 將改變節點數量與關係分布，進而影響
170 檢索結果的完整性與推理連貫性[28]。後續研究進一步驗證，在特定領域中，不恰當的切
171 分策略可能導致知識碎片化，使檢索行為偏向局部資訊，而難以支援跨節點的多步推理需
172 求[29]。除了靜態結構分析外，部分研究亦嘗試將圖結構納入 RAG 系統的檢索與理解流

173 程中。相關方法透過結合文本與圖結構進行檢索與生成，顯示在處理複雜查詢時，結構化
174 表示有助於提升系統對知識關聯的理解能力[30]。然而，這類方法多假設圖譜結構已具備
175 良好品質，較少針對圖譜拓樸特性本身進行系統性診斷與自動化優化，顯示結構品質與檢
176 索行為之間的關聯仍有待進一步深入探討[30]。

177 **3. Methodology**

178 **3.1 System Framework Overview**

179 本研究提出之方法論係以「農業知識圖譜結構化建構」為核心，結合檢索增強生成
180 (Retrieval-Augmented Generation, RAG)架構與大型語言模型(Llama-3)，形成一套可分析、
181 可診斷且可優化的畜牧知識問答系統。不同於過去研究常將模型表現視為單一黑盒結果，
182 本系統設計強調模組化(Modularity)與流程化(Process-oriented)，確保從資料前處理、圖譜
183 建置到檢索生成的各階段設計選擇，皆可獨立分析其對最終問答效能之邊際貢獻。如圖 1
184 所示，整體系統架構主要劃分為四個階段：(1)知識來源蒐集與前處理、(2)知識圖譜建構
185 與索引、(3)圖譜式檢索與問答生成，以及(4)圖譜品質診斷與結構擴增。各階段彼此相互
186 關聯，共同構成具備可重現性(Reproducibility)的農業知識工程流程。



187

188 Fig. 1. The proposed KG-RAG framework architecture. The system comprises four main modules

189 corresponding to Sections 3.2 to 3.5: (A) Knowledge Preprocessing, (B) Graph Construction, (C)

190 Retrieval & Generation, and (D) Quality Diagnosis.

191 如上圖所示，本研究之系統架構主要可分為四個階段：知識來源蒐集與前處理、知識圖譜

192 建構與索引、圖譜式檢索與問答生成，以及圖譜品質診斷與結構擴增。各階段彼此相互關

193 聯，並共同構成完整之農業知識工程與問答流程。在第一階段中，系統以台灣本土山羊產
194 業相關之專業文本作為知識來源，內容涵蓋疾病防治、飼養管理與健康照護等主題。由於
195 原始資料多以非結構化形式存在，系統首先進行文本前處理與切分，將長篇文件轉換為適
196 合後續知識建構之文本單元。此階段中特別關注文本切分策略對後續圖譜結構品質的影響，
197 因此於方法設計上保留不同切分參數（如 chunk size 與 overlap）作為可調變因子，以支援
198 後續之系統性分析。

199 第二階段為知識圖譜建構與索引流程。系統根據前處理後之文本內容，萃取出具代表性的
200 實體與其關係，並以圖結構形式加以組織，形成山羊知識圖譜。相較於僅以向量形式儲存
201 文本片段的傳統 RAG 架構，知識圖譜能明確表達實體之間的語意關聯，為後續的多跳推
202 理與關聯檢索提供結構化基礎。完成圖譜建構後，系統進一步建立對應之索引機制，使其
203 能於查詢階段有效存取相關節點與子圖。第三階段為圖譜式檢索與問答生成流程。在使用
204 者提出問題後，系統首先根據查詢內容進行圖譜檢索，取得與問題語意相關之實體與關聯
205 子圖，並將檢索結果作為外部知識上下文，提供給大型語言模型進行回應生成。此一流程
206 即構成本研究之 Graph-based RAG 問答架構。為避免模型回應僅依賴語言模型內部知識，
207 本研究特別限制生成內容須建立於檢索結果之上，藉此提升回答之可解釋性與可信度。值
208 得注意的是，本研究並未將檢索與生成流程視為固定配置，而是透過調整檢索參數（如檢
209 索數量與子圖範圍），觀察不同設定下系統效能的變化情形。此設計使得檢索策略本身成
210 為可被分析與比較的研究對象，而非僅作為輔助模組存在。

211 第四階段為知識圖譜品質診斷與結構擴增流程。考量實務上由非結構化資料建構之知識圖
212 譜，其結構品質可能存在顯著差異，本研究進一步引入圖譜結構品質指標，用以分析圖譜
213 拓樸特性與問答效能之關聯性。當圖譜呈現星型拓樸或弱連結比例過高時，系統可能無法

214 有效支援多跳推理，使 Graph-based RAG 的行為趨近於一般向量檢索。針對此一情境，本
215 研究設計一套圖譜診斷與結構擴增流程，透過強化實體間之關聯結構，改善知識覆蓋與推
216 理能力，並於實驗中驗證其對問答效能的實際影響。
217 整體而言，本研究之方法論並非僅提出一套固定之智慧問答系統，而是透過模組化架構設
218 計，將知識建構、索引策略、檢索配置與圖譜品質視為可分析的系統變因。此一設計使得
219 後續實驗得以從系統層級探討不同設計選擇對農業知識問答效能之影響，並為實務場域中
220 導入大型語言模型與知識圖譜提供具體且可重現的工程參考。

221 **3.2 Knowledge Acquisition and Preprocessing**

222 在第一階段，本研究以台灣本土山羊產業相關之專業文本作為知識來源，主要依據農業部
223 畜產試驗所出版之技術手冊與專家審定指南，內容涵蓋疾病防治、飼養管理與健康照護等
224 主題。由於原始資料多以非結構化形式(如 PDF 報告、長篇文章)存在，系統首先進行文本
225 清洗與標準化。值得注意的是，文本切分策略(Chunking Strategy)直接影響後續實體抽取
226 的完整性與圖譜的連結密度。因此，本研究並未採用固定參數，而是將切分大小(Chunk
227 Size)(如 128,256,512 tokens)與重疊率(Overlap)保留為可調變因子。此設計旨在支援後續的
228 系統性分析，探討不同粒度的文本單元如何影響知識圖譜的拓樸結構品質，進而尋求最佳
229 的建構參數配置。

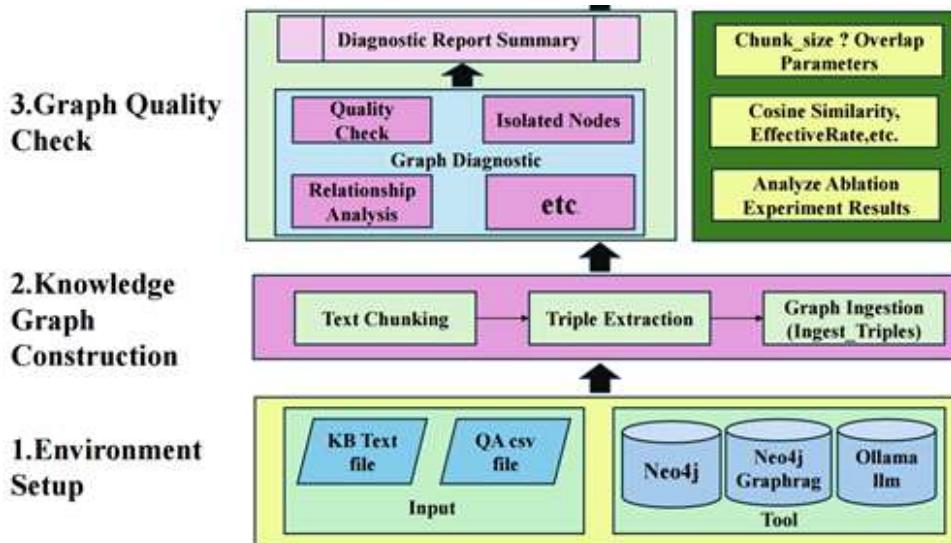


圖 2:知識圖譜建構與圖品質診斷流程架構

230

231

232 3.3 Knowledge Graph Construction and Indexing

233 本研究之圖譜建構流程旨在將前處理後之文本單元轉化為具備語意推理能力的結構化網絡。

234 首先，定義適用於山羊疾病領域的本體論(Ontology)，包含 Disease(疾病)、Symptom(症狀)、

235 Medicine(藥物)、Treatment(治療)等核心實體類別。系統利用大型語言模型進行開放式資

236 訊抽取(Open Information Extraction)，從不同切分設定(Chunking Configurations)的文本單元

237 中萃取實體與關係三元組。相較於傳統 RAG 僅以向量形式儲存文本片段，此種圖譜化表

238 示能明確刻畫實體間的語意邏輯(如「疾病 A—導致→症狀 B」)，為後續的多跳推理提供

239 結構化基礎。完成建構後，所有實體與關係數據被正規化並存入 Neo4j 圖形資料庫中。

240 在索引機制設計上，本研究採取「結構化圖譜」與「文本向量」並行的雙層索引策略

241 (Hybrid Indexing Strategy)。針對圖譜層，系統建立基於節點屬性與關係類型的索引，以支

242 援精確的子圖檢索與多跳路徑查詢；針對文本層，則保留原始文本塊的向量嵌入

243 (Embedding)，以捕捉非結構化的語意相似性。此一互補設計確保系統在圖譜結構完整時

244 能發揮推理優勢，而在圖譜連結稀疏時仍能維持基本的檢索覆蓋率。此外，為支援後續的

245 系統性分析，本研究將索引建構視為實驗變因，分別針對不同文本切分粒度(Granularity)
246 建立對應的獨立索引庫，藉此觀察知識顆粒度對檢索效能的具體影響。
247 考量由非結構化文本自動建構之知識圖譜，極易因文本切分策略或抽取模型的限制而產生
248 結構偏差(Structural Bias)。因此，在建構與索引過程中，系統同步計算並記錄圖譜的拓樸
249 特徵指標，包含節點度數分布(Degree Distribution)、關係密度以及弱連結實體比例。這些
250 指標不僅作為監測圖譜建構品質的依據，更將在後續的「圖譜品質診斷」階段中，作為判
251 定 Graph-based RAG 是否失效及是否需要執行結構擴增的關鍵判斷標準。

252 **3.4 Graph-based Retrieval and Answer Generation**

253 本研究設計了一套可配置的 Graph-based RAG 運作流程，將知識圖譜作為大型語言模型的
254 外部推理引擎。當使用者提出問題時，系統依序執行三個核心步驟：(1)實體鏈接 (Entity
255 Linking)：對輸入問題進行語意解析，辨識關鍵概念並映射至圖譜中的對應節點(Anchors)。
256 (2)子圖檢索(Subgraph Retrieval)：依據設定的跳數(Hops)向外擴展，擷取包含鄰居節點與
257 關係路徑的語意子圖。不同於傳統 RAG 僅檢索離散的文本片段，此子圖保留了實體間的
258 結構化關聯，為多跳推論提供必要的邏輯路徑。(3)生成回答(Response Generation)：將檢
259 索到的結構化三元組線性化(Linearize)為自然語言上下文，作為提示(Prompt)輸入至
260 Llama-3 模型中。
261 為確保回答的可靠性，本研究在生成階段實施嚴格的「知識接地 (Knowledge Grounding)」
262 策略。本研究設計特定的系統提示詞(System Prompt)，明確限制模型必須依據檢索到的圖
263 譜資訊進行回應，嚴禁依賴模型內部的隱含知識編造事實。此設計不僅降低幻覺風險，更
264 提升了系統的可解釋性，使每一個生成的建議都能回溯至圖譜中具體的實體節點與參考文
265 獻來源。

266 值得注意的是，本研究並未將檢索流程視為固定配置，而是將其視為一組「可調式實驗變
267 因」。系統允許動態調整檢索策略，包括檢索深度（Hop Count）、最大回傳節點數以及關
268 聯強度閾值。透過將檢索行為參數化，本研究得以在後續實驗中系統性地比較不同檢索配
269 置對問答效能的影響，進而分析在何種條件下（例如檢索範圍過大引入雜訊，或過小導致
270 資訊不足），Graph-based RAG 能發揮最佳效益。此一分析框架使得檢索策略的最佳化成
271 為具體可量化的工程問題。

7.Reranking Evaluation

6.Retrieval Parameter Ablation

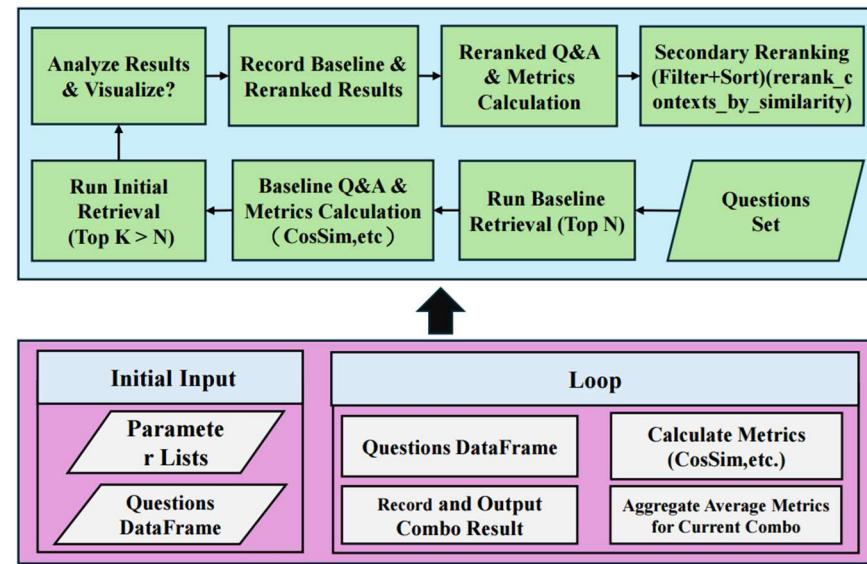


圖 3: 檢索參數消融實驗與重排序評估流程架構

3.5 Graph Quality Diagnosis and Structural Augmentation

275 本研究之第四階段著重於知識圖譜之結構品質診斷與自動化優化，旨在解決由非結構化文
276 本自動建構之知識圖譜在實務應用中常見的結構品質不均問題。由於此類圖譜通常缺乏人
277 工審核與結構約束，其拓樸特性可能出現高度變異，進而影響下游推理與問答任務的效能。
278 因此，本研究引入多項圖譜結構品質指標，以量化節點關係分布與整體連通性，並分析其
279 與 Graph-based RAG 問答行為之關聯性。

280 在結構診斷過程中，系統首先針對整體知識圖譜進行節點度數分布與關係密度分析，以辨
281 識是否存在結構異常現象。為量化圖譜之關係連通程度，本研究定義關係密度指標
282 (Relation Density)，用以衡量在特定品質門檻下關係與節點之相對比例。令 $V(\theta)$ 表示通
283 過品質門檻 θ 篩選後之節點集合， $R(\theta)$ 為其對應之關係集合，則關係密度可表示為 Eq.(1)：

$$\text{RelationDensity}(\theta) = \left| \frac{R(\theta)}{V(\theta)} \right| \quad (1)$$

284 當圖譜中出現單一高中心性節點連結大量周邊實體，但周邊節點之間缺乏有效語義關聯時，
285 該結構將被判定為星型拓樸。此類結構雖在表面上具有高連結度，但實際上缺乏可延展之
286 推理路徑，使得 Graph-based RAG 的檢索與生成行為趨近於關鍵字比對，難以發揮結構化
287 知識所帶來的多步推理優勢。此外，若圖譜中弱語義關係比例過高，亦將導致推理鏈斷裂，
288 降低問答系統對複雜問題的回應能力。

289 為因應上述問題，本研究設計了一套以星型拓樸分析為核心的結構優化流程，首先透過節
290 點度數門檻自動偵測潛在之高中心性節點，並以此為核心抽取對應之局部子圖進行後續分
291 析。對於每一個局部子圖，系統進一步診斷其結構是否呈現星型拓樸特徵；當判定其結構
292 存在異常時，即啟動後續之結構擴增機制，以補強原有知識圖譜中不足的推理連結。如圖
293 Algorithm 1 所示，該方法以高中心性節點為分析起點，透過結構診斷與關係補全的遞進
294 式流程，逐步提升子圖內部及其與全域圖譜之語義連通性，確保知識圖譜具備支撐多步推
295 理與問答任務之結構條件。

Algorithm 1: Star Topology Analysis and Optimization Layer

Input: Knowledge graph KG ; hub threshold τ ; densification strategies set \mathcal{D} ; global inference method \mathcal{I} ; quality threshold θ

Output: Optimized knowledge graph KG'

```
1  $\mathcal{H} \leftarrow \text{DETECTHUBNODES}(KG, \tau);$ 
2 foreach  $h \in \mathcal{H}$  do
3    $\mathcal{S}_h \leftarrow \text{EXTRACTSUBGRAPH}(KG, h);$ 
4    $flag \leftarrow \text{DIAGNOSESTARTOPOLOGY}(\mathcal{S}_h);$ 
5   if  $flag$  then
6      $\mathcal{E}_d \leftarrow \text{APPLYDENSIFICATION}(\mathcal{S}_h, \mathcal{D});$ 
7      $\mathcal{E}_i \leftarrow \text{INFERGLOBALRELATIONS}(\mathcal{S}_h, \mathcal{I});$ 
8      $\mathcal{E}_q \leftarrow \text{HYPOTHETICALQUESTIONSMETHOD}(\mathcal{S}_h);$ 
9      $KG \leftarrow \text{UPDATEGRAPH}(KG, \mathcal{E}_d \cup \mathcal{E}_i \cup \mathcal{E}_q);$ 
10   $KG' \leftarrow \text{RECHECKQUALITY}(KG, \theta);$ 
11  return  $KG';$ 
```

296

297 圖 4:Algorithm 1. Star Topology Analysis and Optimization Layer

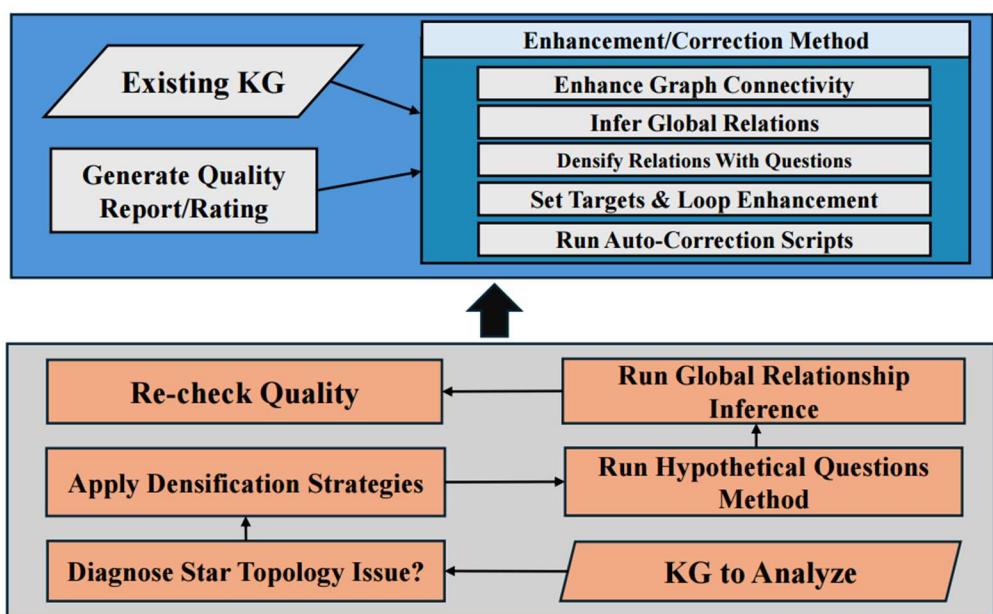
298 Algorithm 1 描述本研究所提出之「星型拓樸分析與優化層」，其核心目的在於自動辨識並
299 修正由非結構化文本建構之知識圖譜中，可能削弱多跳推論能力的星型結構。

300 在輸入階段，演算法以知識圖譜 KG 為基礎，並設定節點度數門檻 τ 、結構擴增策略集合
301 \mathcal{D} 、全域推論方法 \mathcal{I} ，以及品質門檻 θ 作為控制參數。首先，系統透過節點度數分析偵測
302 潛在之高中心性節點集合 H ，此類節點通常連結大量周邊實體，容易形成星型拓樸。
303 接著，對於每一個高中心性節點 $h \in H$ ，系統擷取其局部子圖 S_h ，以保留該節點及其一跳
304 鄰域所構成之結構資訊。隨後，系統執行結構診斷程序以判斷該子圖是否呈現星型拓樸特
305 徵。當診斷結果顯示子圖存在結構異常時，演算法即啟動後續之結構優化流程。
306 在結構擴增階段，演算法同時執行三類互補的關係補全策略。首先，透過局部結構稠密化
307 策略，補強子圖內周邊節點之間的橫向連結，以降低結構過度集中於單一樞紐節點的情形。
308 其次，利用全域推論方法，引入跨子圖與跨概念的潛在關係，以提升整體知識圖譜的語義
309 連通性。最後，透過問題導向之假設性關係生成策略，補充能支援下游問答任務所需的推
310 理關聯。

311 所有新生成之關係集合將即時整合回原始知識圖譜，使圖譜結構逐步由單點輻射型態轉化
 312 為具多路徑推理能力的網狀結構。當所有高中心性節點皆完成處理後，系統重新檢查更新
 313 後知識圖譜之整體結構品質，並依據品質門檻判斷是否已滿足推理型問答任務的需求。最
 314 終，演算法輸出經結構優化後之知識圖譜 KG^* ，供後續 Graph-based RAG 問答流程使用。
 315 在結構擴增過程中，系統透過多源推論策略逐步強化實體間之語義關聯。此一過程同時考
 316 量局部與全域層級之結構補全，藉由推論潛在但未明確表達之關係，提升子圖內部及跨子
 317 圖之連通性。此外，透過問題導向的推理機制，系統得以引入有助於支撐下游問答任務的
 318 假設性關係，使圖譜結構不僅在形式上更為稠密，亦在語義層面更具推理價值。所有新生
 319 成之關係將即時整合回原始知識圖譜中，使整體結構逐步由單點輻射型態轉化為多路徑可
 320 推理的網狀結構。在完成結構擴增後，系統將對更新後之知識圖譜進行品質重檢，並以預
 321 先設定之品質門檻作為判斷依據，以確保圖譜結構已達到支撐推理型問答任務的需求水
 322 準。

5.Graph Enhancement & Correction

4.Star Topology Analysis and Optimization



323

324 圖 5: 星型拓樸分析優化與知識圖譜增強修正之整合流程架構

325 **3.6 Knowledge-Driven Question Answering over Enhanced Knowledge Graphs**

326 為確保知識圖譜能有效支援推理導向之問答任務，第五層（Layer 5）設計一

327 套結合結構增強與品質回饋之迭代式優化機制，針對前述圖譜擴增結果進行

328 進一步修正與整合。形成一套可迭代收斂之知識圖譜增強與修正流程，以確

329 保最終圖譜能有效支援推理導向之問答任務。其整體運作流程 Algorithm 2 所

330 示，核心目的在於透過多種結構增強操作與自動化修正策略，系統性地提升

331 知識圖譜之結構穩定性與推理適用性。

Algorithm 2: Graph Enhancement and Correction Layer

Input: Knowledge graph KG ; enhancement operators

$\{\mathcal{E}_{conn}, \mathcal{E}_{glob}, \mathcal{E}_{qd}\}$; auto-correction scripts \mathcal{S} ; target quality threshold θ ; convergence tolerance ϵ ; maximum iterations $MaxIter$

Output: Enhanced and corrected graph KG^*

```
1  $score^{(0)} \leftarrow 0;$ 
2  $prevScore \leftarrow score^{(0)};$ 
3 for  $iter \leftarrow 1$  to  $MaxIter$  do
4    $\Delta E_{conn} \leftarrow \mathcal{E}_{conn}(KG);$ 
5    $\Delta E_{glob} \leftarrow \mathcal{E}_{glob}(KG);$ 
6    $\Delta E_{qd} \leftarrow \mathcal{E}_{qd}(KG);$ 
7    $KG \leftarrow \text{UPDATEGRAPH}(KG, \Delta E_{conn} \cup \Delta E_{glob} \cup \Delta E_{qd});$ 
8   foreach  $s \in \mathcal{S}$  do
9      $KG \leftarrow \text{RUNAUTOCORRECTION}(KG, s);$ 
10   $score^{(iter)} \leftarrow \text{EVALUATEGRAPHQUALITY}(KG);$ 
11  if  $score^{(iter)} \geq \theta$  or  $|score^{(iter)} - prevScore| < \epsilon$  then
12    break;
13   $prevScore \leftarrow score^{(iter)};$ 
14  $KG^* \leftarrow KG;$ 
15 return  $KG^*;$ 
```

332

333 圖 6:Algorithm 2. Graph Enhancement and Correction Layer

334 在每一輪迭代過程中，系統以當前知識圖譜 KG 作為輸入，並同步啟動三類
335 結構增強操作，分別對應於局部連通性補強(ε_{conn})、全域結構平衡(ε_{glob})
336 以及問題導向之關係補全(ε_{qd})。此多層次增強設計使圖譜得以同時改善局
337 部星型拓樸所造成之推理斷裂問題，並避免關係過度集中於少數高中心性節
338 點，進而維持整體拓樸結構之均衡性。

339 在完成候選關係生成後，系統將新生成之關係集合整合回原始圖譜，並進一
340 步套用一組預先定義之自動化修正腳本 S ，以處理結構擴增過程中可能引入
341 之不一致現象，包括冗餘關係、語義衝突及關係方向不明確等問題。透過此
342 一修正機制，可確保圖譜在持續擴增的同時，仍能維持結構一致性與語義可
343 解釋性。

344 每一輪圖譜更新完成後，系統即重新評估知識圖譜之整體結構品質，其評分
345 結果綜合反映節點關係分布、連通性，以及對推理型問答任務之支援程度。
346 當圖譜品質達到預先設定之門檻值，或前後兩次迭代之品質提升幅度低於收
347 敛容忍值時，系統即終止迭代流程，並輸出最終之優化知識圖譜 KG^* 。
348 透過 Layer 5 迭代式結構增強與品質回饋機制，本研究得以將知識圖譜之結
349 構優化過程與 Graph-based RAG 問答需求進行有效銜接，使圖譜不僅作為靜
350 態知識表示架構，亦能依據推理效能進行動態調整。確保最終生成之知識圖

351 譜具備多路徑推理能力，能支援複雜問題之檢索與生成，並提升整體知識驅
352 動問答系統之穩定性與回應品質。

353 **4. Experiments**

354 **4.1. Experiments**

355 為驗證本研究所提出之 Graph-based RAG 架構以及知識圖譜結構診斷與自動化優化機制之
356 有效性，本章設計並執行一系列實驗，以山羊疾病與飼養管理領域問答任務作為評估情境。
357 實驗目的在於比較不同檢索與推理架構於相同資料與評估條件下之整體表現，並進一步分
358 析索引建構參數、檢索設定以及圖譜結構品質對下游問答行為之影響。本章實驗內容包含
359 三個層面：首先，透過橫向比較實驗評估 LLM-only、Vector-based RAG 與 Graph-based
360 RAG 系統之效能差異；其次，針對關鍵參數進行消融分析，以探討其對問答品質與推論
361 效率之影響；最後，分析圖譜結構優化前後之變化，說明結構品質改善與問答效能提升之
362 關聯性。

363 **4.2. Experiment settings**

364 本研究使用之資料集來自山羊疾病預防與飼養管理相關之專業文本，並建構對應之問答測
365 試集，以反映實務情境中常見之專家諮詢問題。為確保比較結果之公平性，所有實驗均在
366 相同資料來源、相同題庫與相同評估指標下進行。比較系統包含三種主要設定：不使用外
367 部知識之 LLM-only 系統、僅依賴向量相似度進行檢索之 Vector-RAG 系統，以及結合向量
368 檢索與知識圖譜子圖擴展之 GraphRAG 系統；此外，部分實驗亦納入經結構診斷與優化後
369 之圖譜版本，以評估結構改善之影響。在索引建構階段，系統測試不同 chunk size 與
370 overlap 組合，而在檢索階段則調整 top-k 與混合檢索權重參數。所有實驗均於相同軟硬體
371 環境與模型設定下執行，以確保結果具備可重現性。

372 **4.3. Comparative experiments**

373 比較實驗用以評估不同檢索架構於問答任務中的整體表現差異。所有系統均使用相同問題
374 集進行測試，並以語意相似度、有效回答率以及平均回應時間作為評估指標。實驗結果顯
375 示，GraphRAG 系統在整體回答品質與有效回答率方面皆優於 LLM-only 與 Vector-RAG 系
376 統，特別是在需整合多個實體與關係之多跳推理問題中，其優勢更為明顯。此結果顯示，
377 透過知識圖譜提供之結構化關聯資訊，系統能在生成階段獲得較完整之語意脈絡。然而，
378 由於 GraphRAG 需進行子圖擴展與關聯查詢，其平均回應時間相較於其他系統略有增加，
379 反映出品質提升所伴隨之計算成本。

380 **4.4. Experimental result**

381 為進一步探討問答效能差異之成因，本研究將問答評估結果與知識圖譜結構指標進行對照
382 分析。結果顯示，索引建構與檢索參數設定會直接影響圖譜之拓樸特性，例如關係密度、
383 節點連通性以及弱連結實體比例。當索引切分策略不當時，容易導致實體與關係分散於不
384 同文本片段，進而造成圖譜結構破碎，降低子圖擴展之有效性。相對地，適當之索引設定
385 能提升圖譜整體連通性，使 GraphRAG 在檢索階段取得較完整之關聯子圖，進而改善多實
386 體推理類問題之回答品質。上述結果顯示，GraphRAG 之效能提升並非僅來自檢索數量增
387 加，而是來自圖譜結構品質對推理過程所帶來之正向影響。

388 **4.5. Ablation study**

389 為釐清各項設計因素對系統效能之貢獻，本研究進行多組消融實驗，分別針對索引建構參
390 數、檢索配置以及圖譜結構優化策略進行系統性分析。首先，本研究針對不同 chunk size
391 與 overlap 組合進行測試，以量化文本切分策略對知識圖譜結構品質與問答效能之影響。
392 為評估不同設定下生成回答與參考答案之語意一致性，本研究採用平均餘弦相似度

393 (Average Cosine Similarity, AvgCosSim) 作為主要問答品質指標，其定義如下：

$$AvgCosSim(\theta) = \frac{1}{N} \sum_{i=1}^N \frac{a_i(\theta) \cdot g_i}{\|a_i(\theta)\| \|g_i\|} \quad (2)$$

394 其中， $a_i(\theta)$ 表示在參數設定 θ 下系統生成之第 i 筆回答向量， g_i 為對應之參考答案向量， N
395 為測試問題數量。各組參數設定下之圖譜結構指標與 AvgCosineSimilarity 彙整如 Table 1
396 所示。

397 表 1:Effect of chunk size and overlap on knowledge graph structure and semantic QA
398 performance

chunk_size	overlap	chunks	entities	relations	relation_density	average_degree	Avg Cosine Similarity
128	32	4823	11108	10958	0.9865	1.973	0.719634
256	20	3265	8160	7802	0.95	1.91	0.6803
512	64	1792	6855	6230	0.91	1.82	0.6866
1024	128	933	5323	4394	0.83	1.65	0.6962
2048	512	302	4402	3684	0.8369	1.6738	0.731578
4096	512	130	2856	2354	0.8242	1.6484	0.730612
8192	1024	65	1753	1463	0.8346	1.6692	0.701171

399 由表 1 可觀察到，當採用較小之 chunk size 十，例如 128 或 256 時，雖可產生較高數量之
400 文本單元與實體節點，使圖譜在表面上呈現較高的關係密度，然其對應之平均語意相似度
401 (Avg Cosine Similarity) 相對較低，顯示過細之文本切分容易造成語意片段化，限制問答
402 生成階段對完整語境之掌握。相對地，當 chunk size 過大時，如 4096 或 8192 時，雖可保
403 留較完整之語意內容，但文本重疊所帶來之檢索冗餘與圖譜關聯稀釋效應，使得整體圖譜
404 結構連通性與問答效能未能同步提升。

405 綜合比較不同 chunk size 與 overlap 組合後，本研究進一步將索引建構參數選擇問題形式化
406 為一最佳化準則。令 Θ 表示所有候選參數組合集合，則最終採用之參數設定 θ^* 定義為：

$$\theta^* = \arg \max_{\theta \in \Theta} \text{AvgCosSim}(\theta) \quad (3)$$

407 亦即選擇能在整體測試問題上，使平均語意相似度達到最大之參數組合。
408 綜合比較不同組合後可發現，chunk size = 2048、overlap = 512 在圖譜結構品質與問答效能
409 之間取得較佳平衡。此設定在維持適度關係密度與平均節點連結度的同時，亦展現最高之
410 平均語意相似度，顯示其能同時支援結構化子圖檢索與語意一致的答案生成。因此，本研
411 究於後續實驗中採用該組參數作為預設之索引建構配置。

412 其次，檢索參數之消融結果顯示，隨著 top-k 值增加，系統在初期能透過擷取更多相關子
413 圖資訊而提升回答品質；然而，當檢索數量超過一定門檻後，品質增益趨於飽和，且回應
414 時間顯著增加，反映過多檢索結果可能引入雜訊並降低生成效率。

415 最後，透過比較圖譜結構優化前後之實驗結果可觀察到，結構診斷與自動化修正流程能有
416 效降低弱連結實體比例與異常拓樸現象，使知識圖譜由偏向星型結構轉為具多路徑推理能
417 力之網狀結構。在不顯著增加計算成本的情況下，此一結構改善進一步提升了多跳問答任
418 務之整體表現，驗證本研究所提出之圖譜結構優化策略在 Graph-based RAG 系統中的實際
419 效益。

420 **4.6. Case Study**

421 為更直觀說明 GraphRAG 系統於實際問答情境中的推理行為，本研究選取具代表性之問題
422 進行案例分析。分析結果顯示，Vector-RAG 系統主要依賴片段化文本進行生成，部分情
423 況下容易出現資訊不完整或關聯不足之回答；相較之下，GraphRAG 系統可透過知識圖譜
424 擴展取得由多個實體與關係所構成之子圖，使生成結果能更完整反映問題所需之關聯脈絡。

425 透過將最終回答對應回具體之圖譜節點與關係，GraphRAG 展現出較佳之可追溯性與可解
426 釋性，進一步突顯結構化知識於專業領域問答中的實用價值。

427 **5. Discussion**

428 本研究之實驗結果顯示，將知識圖譜引入檢索增強生成架構，並進一步針對圖譜結構
429 品質進行診斷與優化，能在專業領域問答任務中帶來穩定且具意義的效能提升。相較於僅
430 依賴大型語言模型或向量相似度檢索之方法，Graph-based RAG 能透過結構化關聯資訊提
431 供更完整的語意脈絡，特別有助於處理需整合多個實體與關係之多跳推理問題。此結果呼
432 應先前研究中指出知識圖譜在專業問答與推理任務中的輔助價值，並進一步顯示圖譜品質
433 本身即為影響系統表現的重要因素，從結構角度觀察，本研究發現索引建構與檢索參數不
434 僅影響檢索覆蓋率，同時也間接形塑知識圖譜之拓樸特性。當文本切分過於破碎或檢索設
435 定不當時，容易造成實體關係分散與弱連結節點比例上升，使得圖譜在子圖擴展階段難以
436 提供完整的關聯證據。相反地，透過結構品質指標進行診斷並套用自動化修正策略，可有
437 效改善圖譜連通性，進而提升 GraphRAG 在推理階段之穩定性。此結果顯示，圖譜結構品
438 質不應僅被視為資料建構階段的附屬產物，而應被納入系統設計與效能優化流程中加以考
439 量。

440 另一方面，實驗亦顯示 GraphRAG 在效能提升的同時，需付出額外的計算成本。由於
441 子圖擴展與關聯查詢增加了推論負擔，其回應時間相較於 Vector-RAG 略有上升。這反映
442 出實務部署中需在回答品質與推論效率之間取得平衡。然而，透過參數消融結果可觀察到，
443 適當的索引與檢索配置能在不顯著犧牲效率的前提下保留大部分品質增益，顯示該架構具
444 備實際應用的可行性。

445 本研究亦存在若干限制。首先，圖譜結構優化策略仍仰賴既有實體與關係抽取結果，

446 當上游抽取品質不足時，結構修正效果將受到限制。其次，結構品質指標主要反映拓樸層
447 面特性，尚未能全面捕捉語意層次之正確性與一致性。此外，本研究聚焦於單一領域之間
448 答應用，其方法在其他農業或醫療子領域中的泛化能力，仍有待進一步驗證。

449 **6. Conclusions**

450 本研究提出一套結合知識圖譜結構診斷與自動化優化之 Graph-based 檢索增強生成架構，
451 並以山羊疾病與飼養管理領域問答任務作為驗證場域。透過系統性實驗與消融分析，結果
452 顯示，相較於傳統 LLM-only 與 Vector-based RAG 方法，GraphRAG 能在回答品質與有效
453 回答率方面取得穩定提升，特別是在需進行多實體與多關係推理之問題類型中表現更為顯
454 著。進一步指出，GraphRAG 的效能不僅取決於是否使用知識圖譜，而高度依賴圖譜本身
455 之結構品質。透過引入結構品質指標進行診斷，並結合自動化結構修正策略，可有效改善
456 圖譜拓樸特性，進而提升下游問答表現。此結果說明，知識圖譜結構品質在 Graph-based
457 RAG 系統中扮演關鍵角色，應被視為影響推理性能的重要設計因素。

458 整體而言，本研究的主要貢獻在於：第一，提出一個可量化分析知識圖譜結構品質與問答
459 效能關聯之實驗框架；第二，驗證結構優化策略能在不顯著增加計算成本的情況下改善
460 GraphRAG 的推理性為；第三，提供一個可應用於農業專業領域問答之 Graph-based RAG
461 設計範例，補足現有研究多聚焦於模型層而較少關注圖譜結構層之不足。

462 未來研究可從多個方向延伸。其一，可進一步整合語意一致性或事實正確性相關指標，以
463 補足現行結構品質分析之不足；其二，可將本研究之方法應用於其他農業或醫療領域，以
464 驗證其跨領域適用性；其三，隨著大型語言模型能力持續提升，如何在維持可解釋性與可
465 追溯性的前提下，動態結合生成模型與結構化知識，將是後續值得深入探討的研究方向。

466 **Acknowledgements**

467 Collate acknowledgements in a separate section at the end of the article before the
468 references and do not, therefore, include them on the title page, as a footnote to the title or
469 otherwise. List here those individuals who provided help during the research (e.g., providing
470 language help, writing/reviewing assistance, collecting and/or organizing data, funding
471 assistance, project administration, supervision, or proof reading, etc.). Only those individuals,
472 who provided substantive and essential intellectual/scientific contributions, should be listed as
473 authors; others' contributions should be acknowledged here.

474 **Data availability**

475 **References**

- 476 [1] Roussey, C., et al. (2023). C3PO: A crop planning and production process ontology and
477 knowledge graph. *Frontiers in Artificial Intelligence*, 6, 1187090.
- 478 [2] Pan, S., Luo, L., Wang, Y., et al. (2024). Unifying large language models and knowledge
479 graphs: A roadmap. *IEEE Transactions on Knowledge and Data Engineering*.
- 480 [3] Wang, J., Zhang, Z., Wang, L., Li, Y., & Zhang, Y. (2022). Joint extraction of entities and
481 relations in agricultural texts based on attention mechanism. *Computers and Electronics in
482 Agriculture*, 199, 107123.
- 483 [4] Gao, Y., Li, X., Wang, M., & Li, S. (2025). SemSynJE: Semantic and syntactic enhanced joint
484 extraction of entity and relation for sheep disease prevention and treatment. *Computers and
485 Electronics in Agriculture*, 237, 110607.
- 486 [5] Rezayi, S., et al. (2022). AgriBERT: Knowledge-infused agricultural language model for
487 named entity recognition. *Computers and Electronics in Agriculture*, 194, 106727.
- 488 [6] Li, C., Yang, S., Liang, D., Chen, P., & Dong, W. (2025). Construction of a Multi-Source,
489 Heterogeneous Rice Disease and Pest Knowledge Graph Based on the MARBC Model.
490 *Agronomy*, 15(3).
- 491 [7] Chi, H., Liu, J., Wu, J., Lin, K., Gong, J., & Chen, Z. (2023, November). A review of research
492 on multimodal knowledge graphs in agriculture. In *International Conference on Internet of
493 Things and Machine Learning (IoTML 2023)* (Vol. 12937, pp. 347-354). SPIE.
- 494 [8] Yang, T., Mei, Y., Xu, L., Yu, H., & Chen, Y. (2024). Application of question answering
495 systems for intelligent agriculture production and sustainable management: A
496 review. *Resources, Conservation and Recycling*, 204, 107497.
- 497 [9] Bao, J., & Xie, Q. (2022). Artificial intelligence in animal farming: A systematic literature

- 498 review. *Journal of Cleaner Production*, 331, 129956.
- 499 [10] Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., ... & Fung, P. (2023). Survey of hallucination
500 in natural language generation. *ACM Computing Surveys*, 55(12), 1-38.
- 501 [11] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020).
502 Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in neural
503 information processing systems*, 33, 9459-9474.
- 504 [12] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., ... & Wang, H. (2023). Retrieval-augmented
505 generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*, 2(1).
- 506 [13] Jiang, J., Yan, L., Liu, H., Xia, Z., Wang, H., Yang, Y., & Guan, Y. (2025). Knowledge
507 assimilation: Implementing knowledge-guided agricultural large language model.
508 *Knowledge-based systems*, 314, 113197.
- 509 [14] Xiong, J., Zhou, Y., Tian, F., Ni, F., & Zhao, L. (2025). SheepDoctor: A Knowledge Graph
510 Enhanced Large Language Model for Sheep Disease Diagnosis. *Smart Agricultural
511 Technology*, 101001.
- 512 [15] Laktionov, I., Diachenko, G., Kashtan, V., Vizniuk, A., Gorev, V., Khabarlak, K., &
513 Shedlovska, Y. (2024). A comprehensive review of recent approaches and Hardware-Software
514 technologies for digitalisation and intellectualisation of Open-Field crop Production:
515 Ukrainian case study in the global context. *Computers and Electronics in Agriculture*, 225,
516 109326.
- 517 [16] Shao, N., Cui, Y., Liu, T., Wang, S., & Hu, G. (2020). Is graph structure necessary for multi-
518 hop question answering?. *arXiv preprint arXiv:2004.03096*.
- 519 [17] Yasunaga, M., Ren, H., Bosselut, A., Liang, P., & Leskovec, J. (2021). QA-GNN: Reasoning
520 with language models and knowledge graphs for question answering. *arXiv preprint
521 arXiv:2104.06378*.
- 522 [18] Zhang, X., Bosselut, A., Yasunaga, M., Ren, H., Liang, P., Manning, C. D., & Leskovec, J.
523 (2022). Greaselm: Graph reasoning enhanced language models for question answering. *arXiv
524 preprint arXiv:2201.08860*.
- 525 [19] Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., ... & Larson, J. (2024). From
526 local to global: A graph rag approach to query-focused summarization. *arXiv preprint
527 arXiv:2404.16130*.
- 528 [20] Han, H., Wang, Y., Shomer, H., Guo, K., Ding, J., Lei, Y., ... & Tang, J. (2024). Retrieval-
529 augmented generation with graphs (graphrag). *arXiv preprint arXiv:2501.00309*.
- 530 [21] Kim, S., Hwang, S. J., Kim, J., Park, J., & Choi, Y. S. (2025, November). ReGraphRAG:
531 Reorganizing Fragmented Knowledge Graphs for Multi-Perspective Retrieval-Augmented
532 Generation. In *Findings of the Association for Computational Linguistics: EMNLP 2025* (pp.
533 5426-5443).
- 534 [22] Luo, L., Li, Y. F., Haffari, G., & Pan, S. (2023). Reasoning on graphs: Faithful and
535 interpretable large language model reasoning. *arXiv preprint arXiv:2310.01061*.
- 536 [23] Pavlović, J., Krész, M., & Hajdu, L. (2025). Leveraging Spreading Activation for Improved
537 Document Retrieval in Knowledge-Graph-Based RAG Systems. *arXiv preprint*

- 538 arXiv:2512.15922.
- 539 [24] Knierim, A., Kernecker, M., Erdle, K., Kraus, T., Borges, F., & Wurbs, A. (2019). Smart
540 farming technology innovations—Insights and reflections from the German Smart-AKIS hub.
541 NJAS - Wageningen Journal of Life Sciences, 90-91, 100314.
- 542 [25] Rossi, A., Barbosa, D., Firmani, D., Matinata, A., & Merialdo, P. (2021). Knowledge graph
543 embedding for link prediction: A comparative analysis. ACM Transactions on Knowledge
544 Discovery from Data (TKDD), 15(2), 1-49.
- 545 [26] Cattaneo, A., Bonner, S., Martynec, T., Morrissey, E., Luschi, C., Barrett, I. P., & Justus, D.
546 (2024). The Role of Graph Topology in the Performance of Biomedical Knowledge Graph
547 Completion Models. arXiv preprint arXiv:2409.04103.
- 548 [27] Guo, Y., Bo, D., Yang, C., Lu, Z., Zhang, Z., Liu, J., ... & Shi, C. (2024). Data-centric graph
549 learning: A survey. IEEE Transactions on Big Data.
- 550 [28] Zhong, Z., Liu, H., Cui, X., Zhang, X., & Qin, Z. (2025, January). Mix-of-granularity:
551 Optimize the chunking granularity for retrieval-augmented generation. In Proceedings of the
552 31st International Conference on Computational Linguistics (pp. 5756-5774).
- 553 [29] Stäbler, M., Turnbull, S., Müller, T., Langdon, C., Marx-Goméz, J., & Köster, F. (2025,
554 August). The impact of chunking strategies on domain-specific information retrieval in RAG
555 systems. In 2025 IEEE International Conference on Omni-layer Intelligent Systems (COINS)
556 (pp. 1-6). IEEE.
- 557 [30] He, X., Tian, Y., Sun, Y., Chawla, N., Laurent, T., LeCun, Y., ... & Hooi, B. (2024). G-retriever:
558 Retrieval-augmented generation for textual graph understanding and question answering.
559 Advances in Neural Information Processing Systems, 37, 132876-132907.

Author Statement*

For transparency, the journal encourages authors to submit an author statement file outlining their individual contributions to the paper using the relevant CRediT roles: Conceptualization; Data curation; Formal analysis; Funding acquisition; Investigation; Methodology; Project administration; Resources; Software; Supervision; Validation; Visualization; Roles/Writing - original draft; Writing - review & editing. Authorship statements should be formatted with the names of authors first and CRediT role(s) following.

Typical authorship is three to six authors. Efforts related *solely* to "Resources" or "Funding Acquisition" or "Data Collection" or "Project Administration" or "Visualization" or "Reviewing/Editing" or "Supervision" are not, in and of themselves, sufficient contributions to warrant authorship inclusion. Elsevier CRediT statements are somewhat misleading, as intellectual/scientific contributions are the only valid author qualifier. CRediT roles provide a complete inventory of all the efforts by those scientific contributors. Further, each journal independently establishes criteria for authorship regardless of any contributor role taxonomy provided by Elsevier. Please restrict the list of authors to only those members of the research team that made substantive intellectual contributions. Other team members should be recognized in an Acknowledgement (see above).

* Please note: The Author Statement is not part of the manuscript document but should be submitted in a separate editable file in the online submission system. Please use "Author Statement" in the file name.